

Tarea 2 — Estadísticos y pruebas en R

Ph D. Stephanie Hereira-Pacheco

Invalid Date

Instrucciones generales

Crea un script nuevo en RStudio llamado `tarea2_apellido.R`. Escribe todo tu código en ese script, comenta cada paso con `#` y explica con tus propias palabras lo que estás haciendo y los resultados que obtienes. Al terminar entrega únicamente el archivo `.R`.

Dataset de trabajo

Trabajaremos con los datos de pasajeros del **Titanic**. Carga el archivo directamente desde internet con la función `read.csv()` usando la siguiente dirección:

<https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv>

Las variables que usaremos son:

- **Age**: edad del pasajero en años (numérico, tiene valores faltantes)
 - **Fare**: precio del boleto en libras (numérico)
 - **Pclass**: clase del boleto — 1 (primera), 2 (segunda), 3 (tercera)
 - **Sex**: sexo del pasajero
-

Parte 1 — Exploración inicial

1. Carga el dataset y explóralo usando al menos tres de las siguientes funciones: `str()`, `head()`, `dim()`, `summary()`. Describe en un comentario qué te muestra cada una.
 2. Convierte **Pclass** y **Sex** a factor con `factor()`. Verifica el cambio con `str()`. ¿Por qué es importante hacerlo antes del análisis?
 3. La variable **Age** tiene valores faltantes (NA). Usa `sum(!is.na(titanic$Age))` para saber cuántos pasajeros tienen dato de edad. Comenta el resultado.
-

Parte 2 — Estadísticos descriptivos y gráficos

4. Calcula para `Age` y para `Fare` los siguientes estadísticos: media (`mean()`), mediana (`median()`), desviación estándar (`sd()`), mínimo y máximo. Recuerda usar `na.rm = TRUE` en `Age`. Comenta qué te dicen esos valores.
 5. Genera un **boxplot** de `Fare` agrupado por `Pclass`. ¿En qué clase pagaron más por el boleto?
 6. Genera un **boxplot** de `Age` agrupado por `Sex`. ¿Hay diferencias visibles entre hombres y mujeres?
-

Parte 3 — Exploración de normalidad

7. Aplica `shapiro.test()` a `Age` (sin valores NA) y a `Fare`. Para quitar los NA de `Age` puedes usar: `Age_sin_na <- titanic$Age[!is.na(titanic$Age)]`. Interpreta el p-value en cada caso: ¿son normales los datos?
 8. Genera un **Q-Q plot** o un histograma para `Fare`. ¿El gráfico confirma lo que encontraste con la prueba de Shapiro-Wilk?
-

Parte 4 — Pruebas estadísticas

Usa los resultados de la Parte 3 para elegir la prueba correcta en cada pregunta.

9. ¿El precio del boleto (`Fare`) difiere entre las tres clases (`Pclass`)? Si los datos son normales usa `lm() + anova()`; si no lo son usa `kruskal.test()`. Interpreta el resultado.
10. ¿La edad (`Age`) difiere entre hombres y mujeres (`Sex`)? Si los datos son normales usa `t.test()`; si no lo son usa `wilcox.test()`. Interpreta el resultado.
11. ¿Existe correlación entre la edad (`Age`) y el precio del boleto (`Fare`)? Usa `cor.test()` eligiendo el método adecuado: "pearson" si ambas variables son normales, "spearman" si no lo son. Agrega `use = "complete.obs"` para ignorar los NA. Interpreta el coeficiente y el p-value.