

Tarea 1 — R básico para ciencia de datos

Ph D. Stephanie Hereira-Pacheco

2026-05-23

Instrucciones generales

Entrega un **script de R** (.R) con tu nombre en el nombre del archivo (ej. `tarea\apellido.R`). Asegúrate de que el script corra de inicio a fin sin errores, esté bien comentado con `#` y que las interpretaciones de cada ejercicio estén escritas también como comentarios dentro del script. Cada sección aplica los conceptos de una clase diferente.

Dataset a utilizar: C02 — disponible directamente en R base (no requiere instalar paquetes).

Este dataset contiene datos de un experimento sobre la tolerancia al frío en plantas de pasto de dos orígenes geográficos. Las variables son:

Variable	Tipo	Descripción
Plant	Factor (12 niveles)	Identificador de planta individual
Type	Factor	Origen: Quebec o Mississippi
Treatment	Factor	Tratamiento: chilled (enfriada) o nonchilled (no enfriada)
conc	Numérico	Concentración ambiental de CO (mL/L)
uptake	Numérico	Tasa de absorción de CO (mol/m ² seg)

```
# Cargar el dataset
data(C02)
```

Parte 1 — Objetos, estructuras y funciones (Clase 1)

Ejercicio 1. Explora la estructura general del dataset.

- Usa `str()` para ver la estructura del objeto `C02`. ¿Cuántas observaciones y variables tiene?
- Usa `class()` en cada columna del dataframe para identificar el tipo de dato de cada variable.
- Usa `summary()` para obtener un resumen general del dataset.

```
str(C02)
class(C02$Plant)
class(C02$Type)
class(C02$Treatment)
class(C02$conc)
class(C02$uptake)
summary(C02)
```

Ejercicio 2. Trabaja con vectores y matrices.

- Crea un vector llamado `conc_unica` con los valores únicos (sin repetición) de la columna `conc`. ¿Cuántos valores únicos existen? Usa `length()`.
- Extrae los valores de `uptake` de las primeras 12 filas y organízalos en una matriz de 4 filas y 3 columnas. Llámala `mat_uptake`.
- Aplica la función `t()` para transponer `mat_uptake` e imprime el resultado.

```
conc_unica <- unique(C02$conc)
length(conc_unica)

mat_uptake <- matrix(C02$uptake[1:12], nrow = 4, ncol = 3)
mat_uptake
t(mat_uptake)
```

Ejercicio 3. Crea tu propia función.

Escribe una función llamada `coef_variacion` que reciba un vector numérico y devuelva el coeficiente de variación ($CV = \text{desviación estándar} / \text{media} \times 100$). Aplícala a la columna `uptake` del dataset.

```
coef_variacion <- function(x) {
  (sd(x) / mean(x)) * 100
}

coef_variacion(C02$uptake)
```

Ejercicio 4. Exporta datos.

Filtra el dataset para conservar solo las plantas de origen **Quebec** y guarda el resultado en un objeto llamado `C02_quebec`. Exporta este objeto como archivo CSV con el nombre `C02_quebec.csv` usando la función `write_csv()` del paquete `readr`.

```
library(readr)
C02_quebec <- C02[C02$Type == "Quebec", ]
write_csv(C02_quebec, "C02_quebec.csv")
```

Parte 2 — Manipulación de datos (Clase 2)

Ejercicio 5. Acceso y subconjuntos.

- Usando el operador `$`, imprime los valores de la columna `uptake`.
- Selecciona únicamente las columnas numéricas del dataset (`conc` y `uptake`) usando indexación por nombre.
- Filtra las filas donde `uptake > 35` y `Treatment == "nonchilled"`. ¿Cuántas filas cumple esta condición?

```
C02$uptake

C02_num <- C02[, c("conc", "uptake")]
head(C02_num)

C02_filtrado <- C02[C02$uptake > 35 & C02$Treatment == "nonchilled", ]
nrow(C02_filtrado)
C02_filtrado
```

Ejercicio 6. Familia `apply()`.

- Usa `apply()` con `MARGIN = 2` para calcular la media y la desviación estándar de las columnas `conc` y `uptake` simultáneamente. Escribe una función anónima o nombrada que devuelva ambos estadísticos.
- Usa `sapply()` para calcular el valor máximo de `conc` y `uptake`.

```
apply(C02[, c("conc", "uptake")], MARGIN = 2, FUN = function(x) {
  c(media = mean(x), desv_est = sd(x))
})

sapply(C02[, c("conc", "uptake")], max)
```

Ejercicio 7. Estructuras de control.

- Usa `ifelse()` para crear una nueva columna en `C02` llamada `absorcion` que clasifique las plantas como "Alta" si `uptake > 25` o "Baja" si `uptake <= 25`.
- Escribe un bucle `for` que recorra los niveles únicos de `Type` e imprima en consola la media de `uptake` para cada origen.

```
C02$absorcion <- ifelse(C02$uptake > 25, "Alta", "Baja")
head(C02)

for (tipo in unique(C02$Type)) {
  media_tipo <- mean(C02$uptake[C02$Type == tipo])
  print(paste("Origen:", tipo, "- Media uptake:", round(media_tipo, 2)))
}
```

Ejercicio 8. Datos faltantes.

- Verifica si el dataset `C02` tiene valores NA usando `is.na()` y `sum()`. ¿Cuántos hay en total?
- Para practicar, introduce artificialmente 5 valores NA en la columna `uptake` y guárdalos en un nuevo objeto `C02_na`. Luego calcula la media de `uptake` ignorando los NA con `na.rm = TRUE`. Finalmente, reemplaza los NA con la mediana de `uptake`.

```
sum(is.na(C02))

C02_na <- C02
C02_na$uptake[c(3, 10, 25, 50, 72)] <- NA
sum(is.na(C02_na$uptake))

mean(C02_na$uptake, na.rm = TRUE)

C02_na$uptake[is.na(C02_na$uptake)] <- median(C02_na$uptake, na.rm = TRUE)
sum(is.na(C02_na$uptake))
```

Parte 3 — Estadísticos y pruebas (Clase 3)

Ejercicio 9. Estadísticos descriptivos.

Calcula para la variable `uptake` los siguientes estadísticos e interpreta brevemente cada resultado:

- Media, mediana, mínimo y máximo
- Desviación estándar y varianza
- Cuantiles 25 % y 75 %, y rango intercuartil (IQR)
- Coefficiente de variación (usa la función que creaste en el Ejercicio 3)

```
mean(CO2$uptake)
median(CO2$uptake)
min(CO2$uptake)
max(CO2$uptake)

sd(CO2$uptake)
var(CO2$uptake)

quantile(CO2$uptake, 0.25)
quantile(CO2$uptake, 0.75)
IQR(CO2$uptake)

coef_variacion(CO2$uptake)
```

Ejercicio 10. Gráficos descriptivos.

- Genera un boxplot de `uptake` agrupado por `Type` usando la función base `boxplot()`.
- Genera un gráfico de barras con barras de error ($\text{media} \pm \text{sd}$) usando `ggbarplot()` del paquete `ggpubr`, con `Type` en el eje x y `uptake` en el eje y. Colorea las barras por `Treatment`.

```
boxplot(uptake ~ Type, data = CO2,
        main = "Absorción de CO2 por origen",
        xlab = "Origen", ylab = "Uptake (mol/m² seg)")

library(ggpubr)
ggbarplot(data = CO2, x = "Type", y = "uptake",
          fill = "Treatment",
          add = "mean_sd",
          position = position_dodge(0.8),
          palette = "jco",
          xlab = "Origen", ylab = "Uptake (mol/m² seg)")
```

Ejercicio 11. Exploración de normalidad.

Para la variable `uptake`:

- Genera un histograma y una gráfica de densidad. ¿Visualmente parece normal?
- Genera un Q-Q plot con `qqnorm()` y `qqline()`.
- Aplica la prueba de Shapiro-Wilk con `shapiro.test()`. Interpreta el resultado indicando: ¿se cumple el supuesto de normalidad? ¿Por qué?

```
hist(CO2$uptake, main = "Histograma de uptake", xlab = "Uptake")
plot(density(CO2$uptake), main = "Densidad de uptake")

qqnorm(CO2$uptake)
qqline(CO2$uptake)

shapiro.test(CO2$uptake)
```

Interpretación: escribe aquí tu conclusión sobre la normalidad de los datos.

Ejercicio 12. Correlación.

¿Existe una relación lineal entre la concentración ambiental de CO (conc) y la tasa de absorción (uptake)?

- Calcula el coeficiente de correlación de Pearson usando `cor.test()`.
- Interpreta: ¿la correlación es positiva o negativa? ¿Es significativa ($p < 0.05$)?
- Calcula también la correlación de Spearman. ¿Cambia la conclusión?

```
cor.test(CO2$conc, CO2$uptake)

cor(CO2$conc, CO2$uptake, method = "spearman")
```

Interpretación: escribe aquí tu conclusión sobre la relación entre concentración y absorción.

Ejercicio 13. Regresión lineal simple.

Ajusta un modelo de regresión lineal donde `uptake` es la variable respuesta y `conc` la variable predictora.

- Ajusta el modelo con `lm()` y guárdalo en `modelo_co2`.
- Revisa los gráficos diagnósticos (`plot(modelo_co2, which = c(1, 2))`). ¿Se cumplen los supuestos?
- Muestra el resumen con `summary()`. Reporta: intercepto, pendiente, R^2 ajustado y significancia del modelo.

d. Escribe la ecuación de la recta.

```
modelo_co2 <- lm(uptake ~ conc, data = C02)

plot(modelo_co2, which = c(1, 2))

summary(modelo_co2)
```

Interpretación: escribe la ecuación de la recta y explica qué porcentaje de la varianza explica el modelo.

Ejercicio 14. ANOVA de 1 vía.

¿El origen geográfico (**Type**) afecta la absorción de CO₂ (**uptake**)?

- Ajusta el modelo lineal: `lm(uptake ~ Type, data = C02)`.
- Verifica los supuestos con `plot(modelo, which = c(1, 2))`.
- Realiza el ANOVA con `anova()` e interpreta el resultado.

```
modelo_1v <- lm(uptake ~ Type, data = C02)
plot(modelo_1v, which = c(1, 2))
anova(modelo_1v)
```

Interpretación: ¿hay diferencias significativas entre Quebec y Mississippi? ¿Por qué no es necesaria la prueba de Tukey en este caso?

Ejercicio 15. ANOVA de 2 vías.

¿El origen (**Type**), el tratamiento (**Treatment**) o su interacción afectan la absorción de CO₂?

- Ajusta un modelo **aditivo**: `aov(uptake ~ Type + Treatment, data = C02)`.
- Ajusta un modelo **con interacción**: `aov(uptake ~ Type * Treatment, data = C02)`.
- Compara los resultados con `summary()`. ¿La interacción es significativa?

```
anova_adit <- aov(uptake ~ Type + Treatment, data = C02)
summary(anova_adit)

anova_inter <- aov(uptake ~ Type * Treatment, data = C02)
summary(anova_inter)
```

Interpretación: ¿qué factores son significativos? ¿La interacción entre origen y tratamiento modifica el efecto de cada factor?

Ejercicio 16. Prueba de Tukey.

Aunque el ANOVA de 1 vía con `Type` solo tiene 2 grupos, usa el modelo del ANOVA de 2 vías para identificar diferencias entre todos los grupos de `Type:Treatment`.

- Aplica `TukeyHSD()` al modelo de interacción.
- Usa `HSD.test()` del paquete `agricolae` para obtener las letras de agrupamiento.

```
TukeyHSD(anova_inter)

library(agricolae)
tuk <- HSD.test(anova_inter, trt = c("Type", "Treatment"),
               group = TRUE, console = FALSE)
tuk$groups
```

Interpretación: ¿qué combinaciones de origen y tratamiento difieren significativamente entre sí?

Lista de verificación para la entrega

Antes de entregar, asegúrate de cumplir con lo siguiente:

- ☐ Nombre del archivo correcto: `tarea_apellido.R`
- ☐ El script corre de inicio a fin sin errores
- ☐ Cada bloque de código tiene comentarios con `#` explicando qué hace
- ☐ Las interpretaciones (ejercicios que dicen “Interpretación”) están escritas como comentarios `#` dentro del script
- ☐ El script incluye tu nombre y matrícula en las primeras líneas
- ☐ Los 16 ejercicios están respondidos

Fecha de entrega: _____

Valor: _____ puntos